

# 机器学习白板推导系列笔记 (6.5~6.8)

Dexing Huang

dxhuang@bupt.edu.cn

Beijing University of Posts and Telecommunications

日期: 2021 年 11 月 7 日

## 1 约束优化问题

### 1.1 弱对偶性证明

首先给出原问题

$$\begin{cases} \min_{x \in \mathbb{R}^p} f(x) \\ s.t. \quad m_i(x) \leq 0 \quad i = 1, 2, \dots, M \\ \quad \quad n_j(x) = 0 \quad j = 1, 2, \dots, N \end{cases} \quad (1)$$

构造 Lagrange 方程

$$\mathcal{L}(x, \lambda, \eta) = f(x) + \sum_{i=1}^M \lambda_i m_i(x) + \sum_{j=1}^N \eta_j n_j(x) \quad (2)$$

注.  $\lambda_i \geq 0, \eta_j$  无限制

将原问题转化为无约束问题

$$\begin{cases} \min_{x \in \mathbb{R}^p} \max_{\lambda, \eta} \mathcal{L}(x, \lambda, \eta) \\ s.t. \quad \lambda_i \geq 0 \end{cases} \quad (3)$$

简单说明一下为什么无约束问题和原问题等价, 在硬间隔 SVM 中其实已经说过. 其实对于问题 (3), 已经蕴含了  $m_i(x) \leq 0$  的约束条件. 如果  $x$  违反了该约束条件,  $m_i(x) > 0$ , 那么  $\max_{\lambda, \eta} \mathcal{L} \rightarrow \infty$ , 如果满足约束那么  $\max_{\lambda, \eta} \mathcal{L} < \infty$ , 因此

$$\min_x \max_{\lambda, \eta} \mathcal{L} = \min_x \{ \max_{\lambda, \eta} \mathcal{L}, +\infty \} = \min_x \max_{\lambda, \eta} \mathcal{L}$$

所以也称问题 (3) 为原问题的等价表示.

下面讨论原问题的对偶问题

$$\begin{cases} \max_{\lambda, \eta} \min_{x \in \mathbb{R}^p} \mathcal{L}(x, \lambda, \eta) \\ s.t. \quad \lambda_i \geq 0 \end{cases} \quad (4)$$

由弱对偶性可知

$$\min_x \max_{\lambda, \eta} \mathcal{L} \geq \max_{\lambda, \eta} \min_x \mathcal{L} \quad (5)$$

上式的证明在 SVM 一节中举了个鸡头凤尾的例子来定性描述, 下面进行数学的证明, 对于

$\min_x \mathcal{L}(x, \lambda, \eta)$  有

$$\underbrace{\min_x \mathcal{L}(x, \lambda, \eta)}_{A(\lambda, \eta)} \leq \mathcal{L}(x, \lambda, \eta) \leq \underbrace{\max_{\lambda, \eta} \mathcal{L}(x, \lambda, \eta)}_{B(x)} \quad (6)$$

因此

$$\max_{\lambda, \eta} A(\lambda, \eta) \leq \min_x B(x) \quad (7)$$

那么

$$\max_{\lambda, \eta} \min_x \mathcal{L}(x, \lambda, \eta) \leq \min_x \max_{\lambda, \eta} \mathcal{L}(x, \lambda, \eta) \quad (8)$$

## 1.2 对偶关系的几何解释

本节从几何的角度来解释对偶关系. 为了演示方便, 将问题简化为二维, 原问题

$$\begin{cases} \min_{x \in \mathbb{R}^p} f(x) \\ s.t. \quad m_1(x) \leq 0 \end{cases} \quad (9)$$

令  $D$  为定义域,  $D = \text{dom } f \cap \text{dom } m$ , 使用 **Lagrange** 乘子法


$$\mathcal{L}(x, \lambda) = f(x) + \lambda(x) \quad (10)$$

令  $p^* = \min f(x)$ ,  $d^* = \max_{\lambda} \min_x \mathcal{L}(x, \lambda)$ , 令  $G = \{(m_1(x), f(x)) | x \in D\} = \{(u, t) | x \in D\}$ , 将  $p^*, d^*$  用集合表示

$$p^* = \min f(x) = \min t = \inf \{t | (u, t) \in G, u \leq 0\}$$

$$d^* = \max_{\lambda} \min_x \mathcal{L}(x, \lambda) = \max_{\lambda} \min_x (f(x) + \lambda(x)) = \max_{\lambda} \inf \{t + \lambda u | (u, t) \in G\}$$


令  $g(\lambda) = \inf \{t + \lambda u | (u, t) \in G\}$ , 因此  $d^* = \max_{\lambda} g(\lambda)$ , 接下来将  $p^*$  和  $q_*$  表示在图形上, 并假设集合  $G$  为**非凸集**(因为非凸集是一般情况). 凸集 (Convex set) 是一个点集合, 其中每两点之间的直线点都落在该点集合中<sup>1</sup>, 非凸集则不满足该条件.



先表示  $p^*, u < 0$  因此在左半轴

显然  $p^*$  就是左半轴  $t$  的最小值.

<sup>1</sup>维基百科




下面表示  $d^*$

$$g(\lambda) = \inf\{t + \lambda u | (u, t) \in G\}$$

$$d^* = \max_{\lambda} g(\lambda)$$


先看  $g(\lambda)$ ,  $t + \lambda u$  是斜率为  $-\lambda$  的直线, 截距可以取不同值, 记  $\Delta = t + \lambda u$ , 将此直线向上平移, 当与  $G$  相切时设  $\Delta_1 = t + \lambda u$ , 继续上移产生不同的  $\Delta_i$  直到与上边界相切, 不同的截距组成的集合  $\{\Delta_1, \Delta_2, \dots\} = \{t + \lambda u | (u, t) \in G\}$ , 那么  $g(\lambda) = \inf\{t + \lambda u | (u, t) \in G\} = \Delta_1$ , 调整斜率  $\lambda$ , 那么必然可以找到一个  $\lambda^*$  使得直线  $t + \lambda u$  与  $G$  上两个凸点相切, 如下所示



这样就找到了  $d^*$ , 从图中很容易可以看出  $d^* \leq p^*$ , 又因为  $p^* = \max_x f(x)$  与  $\min_x \max_{\lambda} \mathcal{L}(x, \lambda)$  等价, 因此

$$\min_x \max_{\lambda} \mathcal{L}(x, \lambda) \geq \max_{\lambda} \min_x \mathcal{L}(x, \lambda) \quad (11)$$

弱对偶关系成立, 当  $G$  为凸集时, 强对偶关系成立, 从图中也可以很容易得出



另外提一下满足强对偶关系的条件是

凸优化问题 + slater 条件  $\Rightarrow$  强对偶关系(充分非必要)

SVM 是一个二次规划问题, 其天生满足强对偶关系.

### 1.3 slater 条件

slater 条件的描述如下

$$\exists \hat{x} \in \text{relint } D \quad \text{s.t.} \forall i = 1, 2, \dots, M \quad m_i(\hat{x}) < 0$$


注. relint 指的是定义域内, 不含边界

- 对于大多数凸优化问题, slater 条件成立
- 需要找到一个点, 然后验证每一个  $m_i(x)$  都小于 0, 这很难, 因此有一个放松的 slater 条件, 如果有  $k$  个  $m_i(x)$  是仿射函数, 那么只需要验证其他  $M - k$  个即可.

又引出了一个仿射函数的概念, 仿射变换 (Affine transformation), 又称仿射映射, 是指在几何中, 对一个向量空间进行一次线性变换并接上一个平移, 变换为另一个向量空间<sup>2</sup>, 常见的线性函数都是仿射函数.

对于 SVM 问题, 是凸二次优化问题, 且约束条件是仿射函数, 因此符合 slater 条件.

从几何的角度上来看, slater 条件要求需要至少存在一个点其横坐标在  $u$  (即存在  $x$  使得  $m_1(x) < 0$ ) 的负半轴上, 使得切线不会垂直于  $u$  轴, 即斜率不能为无穷大.



### 1.4 KKT 条件

原问题表示如下

$$\begin{cases} \min_{x \in \mathbb{R}^p} f(x) \\ \text{s.t.} \quad m_i(x) \leq 0 \quad i = 1, 2, \dots, M \\ \quad \quad n_j(x) = 0 \quad j = 1, 2, \dots, N \end{cases}$$

其中约束条件  $m_i, n_j$  均可微, 令原问题为  $p^*$ , 最优解为  $x^*$ , 使用 Lagrange 乘子法

$$\mathcal{L}(x, \lambda, \eta) = f(x) + \sum_{i=1}^M \lambda_i m_i(x) + \sum_{j=1}^N \eta_j n_j(x)$$

令  $g(\lambda, \eta) = \min_x \mathcal{L}(x, \lambda, \eta)$ , 对偶问题为

$$\begin{cases} \max_{\lambda, \eta} g(\lambda, \eta) \\ \text{s.t.} \quad \lambda \geq 0 \end{cases}$$

令对偶问题为  $d^*$ , 其最优解为  $\lambda^*, \eta^*$ . 当目标优化问题为凸优化 (convex) 并满足 slater 条件, 则可以推出其满足强对偶关系, 强对偶与 KKT 条件互为充要条件, 并通过 KKT 条件可以求解强

<sup>2</sup>维基百科

## 对偶问题

$$convex + Slater \Rightarrow strong\ duality \Leftrightarrow KKT$$

KKT 条件分为三类: 可行条件, 互补松弛条件, 梯度为 0

$$\begin{cases} \text{可行条件} & m_i(x) \leq 0, n_j(x) = 0, \lambda^* \geq 0 \\ \text{互补松弛条件} & \lambda_i m_i = 0 \\ \text{梯度为0} & \frac{\partial \mathcal{L}}{\partial x} \big|_{x=x^*} = 0 \end{cases} \quad (12)$$

- 可行条件

满足约束条件, 并且需满足隐含条件  $\lambda \geq 0$

- 互补松弛条件

$$\begin{aligned} d^* &= \max_{\lambda, \eta} g(\lambda, \eta) \\ &= g(\lambda^*, \eta^*) \\ &= \min_x \mathcal{L}(x, \lambda^*, \eta^*) \\ &\leq \mathcal{L}(x^*, \lambda^*, \eta^*) \\ &= f(x^*) + \sum_{i=1}^M \lambda_i^* m_i(x^*) + \sum_{j=1}^N \eta_j^* n_j(x^*) \\ &= f(x^*) + \sum_{i=1}^M \lambda_i^* m_i(x^*) \\ &\leq f(x^*) = p^* \end{aligned} \quad (13)$$

在强对偶关系中  $d^* = p^*$ , 因此上述不等号全部改为等号,  $f(x^*) + \sum_{i=1}^M \lambda_i^* m_i(x^*) \leq f(x^*)$  若为等号, 那么

$$\sum_{i=1}^M \lambda_i^* m_i(x^*) = 0 \quad (14)$$

又因为  $\lambda_i^* m_i(x^*) \leq 0$ , 那么  $\lambda_i^* m_i(x^*) = 0$ , 因此将此条件加入 KKT 条件, 也称为 **互补松弛条件**

- 梯度为 0

$\min_x \mathcal{L}(x, \lambda^*, \eta^*) \leq \mathcal{L}(x^*, \lambda^*, \eta^*)$ , 如果取等号的话意味着  $\mathcal{L}$  在  $x^*$  处梯度为 0, 即

$$\frac{\partial \mathcal{L}}{\partial x} \big|_{x=x^*} = 0 \quad (15)$$

以上说明了 KKT 条件为什么与强对偶关系 **互为充要条件**.